



پایان نامه کارشناسی رشته آمار

عنوان :

خوشه‌بندی 570 بیمار سرطان پستان
در ایالت ویسکانسین آمریکا در سال 2021
با استفاده از الگوریتم K-means

پژوهشگر:

یاسمن نوشیروان بابلی

استاد راهنما :

جناب آقای دکتر مهدی علیمحمدی

الله الرحمن الرحيم

فهرست مطالب

1.....	چکیده
2.....	فصل اول: کلیات پژوهش
2.....	1.1. مقدمه
3.....	2.1. مسئله تحقیق
3.....	3.1. هدف تحقیق
3.....	4.1. نوع تحقیق
4.....	فصل دوم: ادبیات پژوهش
4.....	1.2. واژگان کلیدی
4.....	1.1.2. تعریف خوشه‌بندی (Clustering) در داده‌کاوی
6.....	2.1.2. تعریف الگوریتم K-means
7.....	3.1.2. تعریف سرطان پستان
8.....	4.1.2. تعریف نمونه سیتولوژی
9.....	فصل سوم: روش شناسی و پیاده سازی پژوهش
9.....	1.3. جامعه آماری
9.....	2.3. معرفی متغیرها و بررسی همبستگی بین آنها
11.....	3.3. خوشه بندی بیماران
13.....	4.3. نمایش نمودار رکوردها به همراه خوشه‌های حاصل
14.....	5.3. نحوه نمایش رکوردها در نمودار 2 بعدی
16.....	فصل چهارم: نتیجه گیری
16.....	1.4. تجزیه و تحلیل نمودار و نتایج خوشه بندی
16.....	2.4. پاسخ به سوالات تحقیق

17.....منابع

18.....ضمیمہ

سپاسگزارم:

هرچند بندگی فقط شایسته ذات بی همتای خالق هستی آفرین است ولیکن به مصادیق حدیث شریفه (هر کس حرفی به من بیاموزد مرا بنده خود کرده است) معلم هم چنان شأن و مقام والایی دارد که دریای علم و معرفت و پرچم دار توحید هم خود را بنده کسی می داند که حتی یک حرف به او بیاموزد.

لذا بر خود لازم می دانم که از زحمات بی دریغ استاد ارجمند جناب آقای دکتر مهدی علیمحمدی طی چهار سال گذشته، از صمیم قلب تقدیر و تشکر نمایم. از سرکار خانم دکتر فریبا عزیزی و جناب آقای دکتر آرش انوشیروانی که در امر مشاوره این پژوهش مساعدت نمودند و نهایت مراقبت، توجه و دقت خود را مبذول فرموده اند، کمال تشکر را دارم.

در آخر سپاسگزارم از استادان فرهیخته و فرزانه، خانواده عزیزم و دوستانی که در راه کسب علم و معرفت مرا یاری نمودند.

چکیده

سرطان پستان، شایع ترین تومور بدخیم و عامل مهم مرگ ناشی از سرطان در زنان است. عوامل متعددی در تعیین پیش آگهی و رفتار این تومور وجود دارند که بر اساس آن‌ها، می توان روش درمانی مناسب را انتخاب نمود. از مهم ترین این عوامل، درجه بندی (Grading) سرطان پستان می باشد که به طور متداول روی نمونه های بافت شناسی (Histology) انجام می شود. مطالعات مختلف نشان داده اند که نمونه سیتولوژی علاوه بر نقش مهم آن در افتراق ضایعات خوش خیم از بدخیم، می تواند اطلاعات اضافی راجع به درجه بندی تومور ارائه دهد که نتایج آن تا حد زیادی قابل مقایسه با نتایج بدست آمده از نمونه های بافت شناسی است. Grade سرطان نشان دهنده این است که سلول های سرطان پستان تا چه حد در زیر میکروسکوپ غیرعادی به نظر می رسند و ویژگی های آن‌ها چیست.

هدف کلی این پژوهش، تعیین ارزش درجه بندی بر روی نمونه های سیتولوژی بدست آمده از 570 بیمار مبتلا به سرطان پستان و تقسیم این بیماران در سه خوشه با به کارگیری الگوریتم K-means در نرم افزار R است.

این مجموعه داده توسط مرکز بالینی آنالیز تومورهای سرطانی جمع آوری و منتشر شده است که ما برای این پژوهش از طریق وب سایت kaggle به آن دسترسی پیدا کردیم.

داده ها، حاوی اطلاعات و ویژگی های مربوط به تومور این بیماران می باشد که در قالب 30 متغیر آورده شده است.

نتایج این خوشه بندی نشان می دهد که تومورهای 340 نفر از این بیماران، خوش خیم (Grade 1)، تومورهای 145 بیمار، متوسط (Grade 2) و تومورهای 84 بیمار، بدخیم (Grade 3) هستند.

فصل اول : کلیات پژوهش

1.1. مقدمه

سرطان پستان، شایع ترین تومور بدخیم و عامل مرگ ناشی از سرطان در زنان است. سالانه حدود 1 میلیون زن در دنیا به این بیماری مبتلا می شوند. حدوداً از هر ده زنی که به سن 90 سالگی می رسد، یک نفر به سرطان پستان مبتلا می شود.

با وجود تمام تلاش های درمانی و تشخیصی جدید، مرگ و میر ناشی از سرطان پستان از سال 1930 تا 2020 تغییر کمی کرده است. البته در برخی مناطق دنیا، مرگ و میر ناشی از سرطان پستان شروع به کاهش کرده است که علت آن، تشخیص زودرس و بهبود روش های درمان است.

روش های تشخیصی متعددی برای سرطان پستان وجود دارد که اغلب مرحله به مرحله انجام شده و مکمل هم می باشند.

بعد از تشخیص بدخیمی، عوامل متعددی در تعیین رفتار تومور وجود دارند که بر اساس آن ها می توان روش درمانی مناسب را انتخاب کرد. از مهم ترین این عوامل، درجه بندی (Grading) سرطان پستان می باشد که به طور متداول روی نمونه های بافت شناسی (Histology) انجام می شود. مطالعات مختلف نشان داده اند که نمونه سیتولوژی علاوه بر نقش مهم آن در افتراق ضایعات خوش خیم از بدخیم، می تواند اطلاعات اضافی راجع به درجه بندی تومور ارائه دهد که نتایج آن تا حد زیادی قابل مقایسه با نتایج بدست آمده از نمونه های بافت شناسی است.

توانایی پیش بینی درجه بندی (Grade) تومور روی نمونه های سیتولوژی پستان، به خصوص در موارد انجام کموتراپی قبل از عمل (neoadjuvant) برای بیمارانی که خارج کردن تومور به طریق جراحی (mastectomy) بهترین انتخاب نیست، بسیار کاربردی است. هر چه اطلاعات به دست آمده از نمونه های سیتولوژی کامل تر باشند، به جراح در مورد درمان و بهبود روند درمان بیمار کمک بیشتری می کنند.

2.1. مسئله تحقیق

دانستن Grade سرطان پستان برای درک سرعت رشد و گسترش سرطان بسیار مهم است. چرا که بسته به Grade سرطان پستان است که بهترین روش درمانی تعیین شده و شانس درمان سرطان سنجیده می شود.

Grade سرطان نشان دهنده این است که سلول های سرطان پستان تا چه حد در زیر میکروسکوپ غیر عادی به نظر می رسند و ویژگی های آن ها چیست. Grade سرطان را تنها از طریق برداشتن بخشی از سلول های سرطانی و بررسی در آزمایشگاه است که می توان تعیین کرد. Grade سرطان پستان بر این اساس تعیین می شود که رفتارهای سلول های سرطانی چقدر عادی یا غیر عادی است. Grade سرطان به پیش بینی نتیجه بیماری و انتخاب روش درمانی مناسب، کمک زیادی می کند. Grade پایین سرطان پستان، یعنی سرطان پستان 1 Grade نشان دهنده این است که سرطان به کندی رشد می کند و شانس سرایت کردنش کم است. در حالی که Grade بالای سرطان پستان، یعنی سرطان پستان 3 Grade نشان می دهد که سرطان به سرعت رشد می کند و احتمال سرایت کردنش به دیگر بخش ها زیاد است. طبیعتاً شناخت Grade سرطان به پزشکان در اهمیت زمان بندی درمان سرطان و بهترین روش درمانی کمکی اساسی خواهد کرد.

پس مسئله اصلی این پژوهش، تعیین Grade سرطان پستان بیماران مربوطه، به کمک اطلاعات به دست آمده از نمونه سیتولوژی آن ها می باشد.

3.1. هدف تحقیق

هدف کلی این پژوهش، تعیین ارزش درجه بندی بر روی نمونه های سیتولوژی بدست آمده از 570 بیمار مبتلا به سرطان پستان و تقسیم این بیماران در سه خوشه با به کارگیری الگوریتم K-means است.

4.1. نوع تحقیق

این تحقیق از نوع پژوهش کاربردی می باشد. زیرا هدف آن تعیین بهترین روش درمانی، برآورد طول دوره درمان و سنجیدن شانس درمان بیمار سرطانی می باشد.

فصل دوم : ادبیات پژوهش

1.2. واژگان کلیدی

1.1.2. تعریف خوشه‌بندی (Clustering) در داده‌کاوی : یکی از روش‌های کاوش در داده‌های انبوه و کشف اطلاعات و دانش از این داده‌ها، داده‌کاوی می‌باشد. برای استخراج الگو از این داده‌ها الگوریتم‌های متعددی مورد استفاده قرار می‌گیرند و هر کدام موارد استفاده مخصوص به خود را دارند. یکی از مهم‌ترین و پرکاربردترین تکنیک‌های داده‌کاوی استفاده از الگوریتم‌های خوشه‌بندی است. خوشه‌بندی یا دسته‌بندی داده‌ها با استفاده از شباهت‌های ذاتی آن‌ها داده‌های مشابه را در یک گروه قرار می‌دهد. و بر اساس این دسته‌بندی و شباهت به کشف الگو و استخراج نهفته در ذات داده‌ها می‌پردازد. و یافتن این الگوها مدیریت داده‌ها برای کاربردهای مختلف بسیار آسان می‌کند.

خوشه‌بندی یک روش یادگیری بدون نظارت است. یک روش یادگیری بدون نظارت روشی است که در آن دیتاست مورد نظر حاوی داده‌هایی است بدون برچسب هدف یا گروهی که داده به آن متعلق است. به طور کلی، از آن به عنوان فرایندی برای یافتن ساختار یا الگویی معنی‌دار برای دسته‌بندی داده‌ها بکار می‌رود.

خوشه‌بندی وظیفه تقسیم جمعیت یا نقاط داده به تعدادی گروه است به گونه‌ای که نقاط داده در گروهی که عضو است بیشترین شباهت را به سایر نقاط داده در همان گروه داشته باشد و با نقاط داده در گروه‌های دیگر شباهتی نداشته باشد. در اصل مجموعه‌ای از اشیاء یا داده‌ها بر اساس شباهت و عدم شباهت تقسیم بندی می‌شوند؛ این یک وظیفه اصلی برای کاوش داده و یک روش برای تجزیه و تحلیل داده‌های کلان است که در بسیاری از زمینه‌ها از جمله شناخت الگو، تجزیه و تحلیل تصویر، بازیابی اطلاعات، بیوانفورماتیک، فشرده‌سازی داده‌ها، گرافیک رایانه و یادگیری ماشین مورد استفاده قرار می‌گیرد.

الگوریتم‌های خوشه‌بندی داده‌هایی را که ویژگی‌های مشابه به هم و نزدیک دارند را در دسته‌های جداگانه که به آن خوشه گفته می‌شود قرار می‌دهند. با نگاهی ساده‌تر به مسئله خوشه‌بندی در میابیم که خوشه‌بندی می‌تواند همان دسته‌بندی باشد که روزانه بارها بدون توجه به این‌که این عمل را انجام می‌دهیم از آن برای دسته‌بندی وسایل استفاده می‌کنیم. زمانی‌که با تعدادی اشیاء با صفات مختلف ولی محدود رو به رو هستیم به راحتی اشیاء را دسته‌بندی می‌کنیم.

از کاربرد خوشه بندی می توان به موارد زیر اشاره کرد:

- **بازاریابی :** خوشه بندی می تواند در زمینه های مختلف بازاریابی کاربرد داشته باشد به طور مثال از خوشه بندی برای توصیف و کشف رفتار مشتری، توانایی خرید مشتری و برای انجام تبلیغات بهینه از اهداف بازاریابی می توان استفاده کرد.
- **زیست شناسی :** یکی دیگر از توانایی های خوشه بندی این است که آن را برای طبقه بندی در میان گونه های مختلف گیاهان و حیوانات استفاده کرد و این خود به زیست شناسان بسیار کمک می کند.
- **کتابخانه ها :** در خوشه بندی کتاب های مختلف بر اساس موضوعات و اطلاعات استفاده می شود و بسیار کار جست و جوی کتاب را راحت تر کرده است.
- **بیمه :** برای تأیید مشتریان ، بیمه نامه های آنها و شناسایی کلاهبرداری ها به کار می رود.
- **برنامه ریزی شهری :** برای ساختن گروه هایی از اطلاعات خانه ها و بررسی ارزش های آنها بر اساس موقعیت جغرافیایی و سایر عوامل موجود استفاده می شود و از این گروه ها برای قیمت گذاری استفاده می شود تا نظر اشخاص در تعیین قیمت کمتر تاثیرگذار باشد.
- **مطالعات زلزله :** با بررسی مناطق زلزله زده و بررسی وضعیت صفحات زمین می توان مناطق خطرناک را تعیین کرد.
- **تقسیم بندی بازار :** بخش بندی بازار ، هدف گیری شرکت ها را به سمت بازارهای مشخص تري هدایت می کنند تا ارتباط موثر تري با مشتریان صورت پذیرد. که بدین وسیله بتوانند زمینه تصمیم گیری سریع و منطبق با واقعیت را فراهم کنند.
- **تحلیل شبکه اجتماعی :** تشخیص انجمن ها و خوشه بندی گراف در یک شبکه اجتماعی به ساده سازی و تحلیل بهتر آن کمک می کند. انجمنها گروه هایی از نودهای شبکه هستند که ارتباط تنگاتنگی با هم دارند و با نودهای بیرون از شبکه ارتباط نسبتا کمی دارند. بعنوان مثال اگر ارتباطات اجتماعی افراد را در یک شبکه اجتماعی داشته باشیم دوستان هم کلاس در یک دانشکده از یک دانشگاه ممکن است تشکیل یک گروه با ارتباطات تنگاتنگ بدهند و در حقیقت یک انجمن در این شبکه اجتماعی باشند.
- **گروه بندی نتایج جستجو :** گروه بندی و به نظم در آوردن نتایج جستجو در بازاریابی اطلاعات، بخصوص وقتی حجم منابع پیشنهاد شده بسیار زیاد است به کاربران در بدست آوردن اطلاعات مورد نظر کمک می کند. بازاریابی و سازماندهی مدارك همواره بر اساس ویژگی های هر مدرك صورت می پذیرد.

- **تصویربرداری پزشکی و پزشکی :** در تصویربرداری PET تجزیه‌ی خوشه‌ای می‌تواند برای تمایز بین انواع مختلف بافت در یک تصویر سه بعدی برای بسیاری از اهداف مختلف مورد استفاده قرار گیرد. کاربرد خوشه‌بندی در پزشکی می‌تواند برای تجزیه و تحلیل الگوهای مقاومتی آنتی‌بیوتیکی، طبقه‌بندی ترکیبات ضد میکروبی مطابق با مکانیسم عمل آن‌ها، طبقه‌بندی آنتی‌بیوتیک‌ها بر اساس فعالیت ضد باکتری آن‌ها استفاده شود.
- **سیستم توصیه گر :** سیستم‌های توصیه شده به منظور توصیف ایتیم جدید بر اساس سلیقه کاربر طراحی شده‌اند. با استفاده از الگوریتم‌های خوشه بندی می‌توان سیستم‌های پیشنهاد دهنده ای طراحی کرد که بر اساس سلیقه و ذائقه مخاطب به او کالای مورد نیاز، فیلم و یا موزیک و غیره پیشنهاد دهند. بر اساس جست و جوی قبلی یا برای پیش‌بینی ترجیحات کاربر بر اساس ترجیحات دیگر کاربران در خوشه کاربر استفاده می‌کنند.

2.1.2. تعریف الگوریتم K-means : الگوریتم k-means یکی از ساده‌ترین و محبوب‌ترین الگوریتم‌های خوشه بندی است که در داده‌کاوی بخصوص در حوزه ی یادگیری نظارت نشده به کار می‌رود. معمولاً در حالت چند متغیره، باید از ویژگی‌های مختلف اشیاء به منظور طبقه‌بندی و خوشه کردن آن‌ها استفاده کرد. به این ترتیب با داده‌های چند بعدی سروکار داریم که معمولاً به هر بعد از آن، ویژگی یا خصوصیت گفته می‌شود. با توجه به این موضوع، استفاده از توابع فاصله مختلف در این جا مطرح می‌شود. ممکن است بعضی از ویژگی‌های اشیاء کمی و بعضی دیگر کیفی باشند. مراحل پیاده سازی الگوریتم K-means :

1. تعیین تعداد خوشه‌ها (K) توسط کاربر.
2. انتخاب تصادفی K رکورد به عنوان مراکز خوشه‌های اولیه.
3. شکل دادن K خوشه بر اساس میزان فاصله هر رکورد تا مراکز انتخابی، به گونه‌ای که برای هر رکورد، فاصله تا تمام مراکز محاسبه می‌شود و نهایتاً رکورد متعلق به خوشه با کمترین فاصله است.
4. یافتن مرکز ثقل برای هر یک از K خوشه و جایگزین کردن مرکز هر خوشه با این مقدار میانگین.
5. تکرار گام 3 تا 5 تا حصول همگرایی و پایان الگوریتم.

3.1.2. تعریف سرطان پستان: سرطان پستان نوعی از سرطان است که عملکرد تقسیم سلولی در سلول‌های پستان را دچار اختلال می‌کند. سلول‌های سرطانی پستان در شخصی که مبتلا شده، بدون کنترل و بیش از حدی که لازم است تکثیر می‌شوند. سرطان پستان انواع مختلفی دارد. نوع آن بستگی به این دارد که کدام نوع از سلول‌های پستان دچار این اختلال شده‌اند. این سرطان ممکن است از جاهای مختلفی در پستان آغاز شود.

پستان سه بخش کلی دارد:

- **لوبول‌ها:** غده‌هایی که شیر در آنها ساخته می‌شود.
- **مجراها:** لوله‌هایی که شیر را از لوبول به نوک پستان می‌رسانند.
- **بافت همبند:** بافت لیفی و بافت چربی که بخش‌های دیگر پستان را در برمی‌گیرد و کنار هم نگاه می‌دارد.

بیشتر سرطان‌های پستان از مجراها یا لوبول آغاز می‌شود. سلول‌های سرطانی می‌توانند از طریق رگ‌های خونی و مسیرهای لنفاوی به سمت بیرون از پستان حرکت کنند و در بقیه‌ی بدن گسترش پیدا کنند. در این حالت می‌گوییم سرطان متاستاز رخ داده است.

شایع‌ترین انواع سرطان پستان این دو نوع هستند:

- **سرطان تهاجمی مجاری شیر پستان:** در این نوع از سرطان پستان، سلول‌های سرطانی در مجرا شکل می‌گیرند. بعد از پیشروی کم‌کم به سمت بیرون از آن حرکت می‌کنند و به سایر قسمت‌های پستان راه پیدا می‌کنند. این سلول‌ها حتی ممکن است از پستان خارج شوند و سایر مناطق بدن را تحت تأثیر قرار بدهند.
- **سرطان تهاجمی لوبولی پستان:** در این نوع از سرطان، سلول‌های سرطانی اول در لوبول شکل می‌گیرند و سپس به بقیه‌ی نقاط پستان و خارج از آن حرکت می‌کنند.

سرطان پستان انواع دیگری هم دارد که شایع نیستند مثل بیماری پازه، سرطان مدولاری، سرطان موسینی و سرطان التهابی پستان.

4.1.2. تعریف نمونه سیتولوژی : سیتولوژی یا سیتوپاتولوژی استفاده از تکنیک‌های تشخیصی ویژه برای بررسی سلول‌های جدا شده از بافت‌ها برای تعیین علت و ماهیت یک بیماری است.

نمونه‌های سلول ممکن است در طی آزمایش‌های معمول تشخیصی مانند برونکوسکوپی و سیستوسکوپی جمع‌آوری شود.

برای جمع‌آوری سلول‌ها از مکان‌های خاص برای تشخیص می‌توان از آزمایش‌های خاص مانند آزمایش Papanicolaou که به عنوان تست پاپ یا آسپیراسیون با سوزن ریز نیز شناخته می‌شود استفاده کرد.

تجزیه و تحلیل نمونه‌های سلول اغلب یک روند سریع است، اما برای شناسایی صحیح سلول‌هایی که خطر بالقوه‌ای برای بیمار دارند، مانند سلول‌های پیش‌سرطانی، سرطانی یا آلوده، نیاز به آموزش‌های تخصصی دارد.

این وظیفه یک متخصص سیتوپاتولوژیست آموزش دیده است. یعنی یک پزشک عمومی که تحت آموزش‌های مازاد قرار گرفته تا نتایج آزمایشات سیتوپاتولوژی را به درستی بررسی و تفسیر کند.

اولین آزمایشی که در زمینه سیتوپاتولوژی ایجاد شد، تست پاپ بود. به طور گسترده‌ای موفقیت‌آمیزترین آزمایش غربالگری در تاریخ پزشکی در نظر گرفته می‌شود و همچنان بخشی حیاتی از سیتوپاتولوژی مدرن است.

از آن زمان سیتوپاتولوژی نقشی اساسی در تشخیص بالینی بیماری‌های سرطانی و پیش‌سرطانی، تومورهای خوش‌خیم و برخی بیماری‌های عفونی داشته است. این رشته اکنون طیف گسترده‌ای از تکنیک‌ها را برای انواع بافت‌ها در بر می‌گیرد.

فصل سوم : روش شناسی و پیاده سازی پژوهش

1.3. جامعه آماری :


جامعه آماری این پژوهش، کلیه ساکنین ایالت ویسکانسین آمریکا می باشد و نمونه‌ی این پژوهش به صورت نمونه گیری عمدی یا غیرتصادفی در دسترس قرار دارد. بنابراین به صورت عمدی، مرکز بالینی آنالیز تومورهای سرطانی را به عنوان نمونه انتخاب و اطلاعات جمع‌آوری شده توسط این مرکز در سال 2021 مورد مطالعه قرار گرفته است. (دسترسی محقق به این اطلاعات از طریق وبسایت kaggle بوده است)

2.3. معرفی متغیرها و بررسی همبستگی بین آنها

radius mean	میانگین شعاع
texture mean	میانگین بافت
perimeter mean	میانگین محیطی
area mean	میانگین منطقه
smoothness mean	میانگین صافی
compactness mean	میانگین فشردگی
concavity mean	میانگین تقعر
concave points mean	میانگین نقاط مقعر
symmetry mean	میانگین تقارن
fractal dimension mean	میانگین ابعاد فراکتال
radius se	انحراف معیار شعاع
texture se	انحراف معیار بافت
perimeter se	انحراف معیار محیطی
area se	انحراف معیار منطقه
smoothness se	انحراف معیار صافی
compactness se	انحراف معیار فشردگی
concavity se	انحراف معیار تقعر
concave points se	انحراف معیار نقاط مقعر
symmetry se	انحراف معیار تقارن
fractal dimension se	انحراف معیار ابعاد فراکتال

radius worst	بدترین شعاع
texture worst	بدترین بافت
perimeter worst	بدترین محیطی
area worst	بدترین منطقه
smoothness worst	بدترین صافی
compactness worst	بدترین فشردگی
concavity worst	بدترین تقعر
concave points worst	بدترین نقاط مقعر
symmetry worst	بدترین تقارن
fractal dimension worst	بدترین ابعاد فراکتال

ویژگی‌های بالا برای تومور هر یک از بیماران سرطانی مذکور، در نظر گرفته شده و میزان همبستگی دو به دو برای این متغیرها به صورت زیر است:




ملاحظه می‌شود که متغیرهای perimeter mean و radius mean (corr = 1.00) و area mean و perimeter (corr = 0.99) و radius mean و area worst (corr = 0.98) و radius worst و area worst (corr = 0.99) و perimeter worst (corr = 0.98) دو بیشترین همبستگی را دارند.

3.3. خوشه بندی بیماران

رکوردهای مربوط به تومور 570 نفر بیمار سرطان پستان را با به کارگیری الگوریتم K-means در نرم‌افزار R، به سه خوشه تقسیم کردیم.

اندازه رکوردهای مربوط به هر خوشه 84، 146 و 340 می‌باشد که سهم تعداد رکوردهای هر خوشه از تعداد کل رکوردها در نمودار زیر بهتر نمایش داده شده است:



پراکندگی درون هر یک از این خوشه‌ها (مجموع مربعات فاصله هر رکورد تا مرکز خوشه مربوطه) به ترتیب 30117250، 10030190، 10369391 می‌باشد. به این ترتیب مقدار SSW برابر است با

$$50516831 = 30117250 + 10030190 + 10369391$$

همچنین پراکندگی بین این خوشه‌ها (SSB)، 206160412 می‌باشد.

از آنجا که در خوشه بندی به دنبال خوشه‌هایی همگن هستیم، به طوری که شباهت رکوردها درون هر خوشه حراکثر و با رکوردهای خارج از هر خوشه حداقل باشد، از آماره‌ی F برای توقف الگوریتم استفاده می‌کنیم:


$$F = \frac{MSB}{MSW} = \frac{\frac{SSB}{K-1}}{\frac{SSW}{N-K}}$$

که در آن N تعداد کل مشاهدات و K تعداد خوشه‌هاست.

انتظار داریم که در تکرارهای متوالی الگوریتم، مقدار این آماره افزایش یابد. به این ترتیب خوشه بندی که بیشترین مقدار آماره F را داشته باشد، بهینه است.

از آنجایی که بر خلاف خوشه بندی دستی، خوشه بندی با نرم افزار، بدون نیاز به تکرار الگوریتم، بهترین خوشه بندی ممکن را ارائه می‌دهد، بنابراین مقدار آماره F خوشه بندی حاصل، بیشترین مقدار و برابر با 4.081024 می‌باشد.

4.3. نمایش نمودار رکوردها به همراه خوشه‌های حاصل



طبق نمودار نیز ملاحظه می‌شود بخش زیادی از رکوردها متعلق به خوشه سوم است. بعد از آن خوشه دوم بیشترین سهم را دارد و در نهایت بخش کمی از رکوردها در خوشه اول قرار گرفته است.

5.3. نحوه نمایش رکوردها در نمودار 2 بعدی

در موضوع مورد بررسی پژوهش ما، اطلاعات جمعیتی برای تعدادی از بیماران فعلی یا بالقوه داریم که می‌خواهیم با گروه بندی افراد بر اساس ویژگی‌های مشاهده شده، دریابیم که چه نوع بیمارانی شبیه یکدیگر هستند. این به عنوان یک مشکل خوشه‌بندی شناخته می‌شود. در اینجا ما سعی در پیش‌بینی متغیر خروجی نداریم. به جای پیش‌بینی یک متغیر خروجی خاص، ما علاقه‌مندیم که تشخیص دهیم بر اساس اندازه‌گیری‌های بیان ژن، گروه‌ها یا خوشه‌هایی در میان رده‌های سلولی وجود داشته باشد یا خیر. پرداختن به این سوال دشوار است، تا حدی به این دلیل که هزاران اندازه‌گیری بیان ژن در هر رده سلولی وجود دارد، که تجسم داده‌ها را دشوار می‌کند.

ممکن است این سوال در ذهنمان ایجاد شود که ما چگونه تمام متغیرهای جمع‌آوری شده را در نظر بگیریم و بر روی تعداد کمی از آن‌ها تمرکز کنیم؟ در شرایط فنی، شما می‌خواهید ابعاد فضای ویژگی خود را کاهش دهید. با کاهش ابعاد فضای ویژگی، روابط کمتری بین متغیرها وجود دارد که می‌توانید در نظر بگیرید و به احتمال کمتری مدل خود را بیش‌برازش می‌کنید (توجه: به این معنی نیست که مشکل بیش‌برازش دیگر اتفاق نمی‌افتد، اما ما به سمت درستی حرکت می‌کنیم)

تعجبی ندارد که کاهش ابعاد فضای ویژگی، کاهش ابعادی نامیده می‌شود. روش‌های زیادی برای کاهش ابعاد وجود دارد، اما اغلب این روش‌ها به یکی از این دو دسته تقسیم می‌شوند:

- حذف ویژگی
- استخراج ویژگی

حذف ویژگی همان چیزی است که به نظر می‌رسد: ما فضای ویژگی را با حذف مشخصه‌ها کاهش می‌دهیم. مزایای روش‌های حذف ویژگی شامل سادگی و حفظ تفسیر متغیرهای شما است.

به عنوان عیب این روش، شما هیچ اطلاعاتی از آن متغیرهایی که حذف کرده‌اید کسب نمی‌کنید. با حذف مشخصه‌ها، تمام سودی که متغیرهای حذف شده می‌توانند به شما دهند را از دست می‌دهید.

اما استخراج ویژگی به این به این مشکل نمی خورد. بگذارید بگوییم ما ده متغیر مستقل داریم. دراستخراج ویژگی، 2 متغیر مستقل جدید ایجاد می کنیم که هر متغیر مستقل جدید ترکیبی از هر 15 متغیر مستقل قدیمی است. با این حال، ما این متغیرهای مستقل جدید را به روشی خاص ایجاد کرده و این متغیرهای جدید را بر اساس چگونگی پیش بینی متغیر وابسته ما، ترتیب می دهیم.

ممکن است بگویید: کاهش ابعاد کجا وارد بازی می شود؟ خب، ما هر تعداد از متغیر های مستقل را که می خواهیم، حفظ می کنیم، اما ما کم اهمیت ترین را حذف می کنیم. از آنجا که ما متغیرهای جدید را بر اساس این که کدام یک بهتر متغیر وابسته ما را پیش بینی می کنند، ترتیب دادیم، می دانیم کدام متغیر مهم ترین و کدام یک کم اهمیت ترین متغیر است. اما به این دلیل که این متغیرهای مستقل جدید ترکیبی از متغیرهای قدیمی ما هستند، ما هنوز ارزشمند ترین قسمت های متغیرهای قدیمی مان را حفظ می کنیم، حتی زمانی که یک یا چندمتغیر جدید را حذف می کنیم!

تحلیل مولفه های اصلی (PCA) تکنیکی برای استخراج مولفه ها است؛ بنابراین مولفه های ورودی ما را به یک روش خاص ترکیب می کند، سپس می توانیم کم اهمیت ترین مولفه ها را حذف کنیم در حالی که هنوز ارزشمند ترین قسمت های تمام مولفه ها را حفظ می کنیم. هر یک از متغیرهای جدید بعد از PCA همگی مستقل از یکدیگر هستند. این یک مزیت است زیرا فرضیات مدل خطی نیازمند این است که متغیرهای مستقل ما از یکدیگر مستقل باقی بمانند. به عنوان مثال اگر تصمیم بگیریم که یک مدل رگرسیون خطی را با این متغیرهای جدید برآزش کنیم (رگرسیون مولفه های اصلی)، این فرض لزوماً ارضا خواهد شد.

فصل چهارم : نتیجه‌گیری

1.4. تجزیه و تحلیل نمودار و نتایج خوشه بندی

طبق بررسی‌هایی که روی رکوردهای مربوط به هر خوشه و اندازه‌ی ویژگی‌های آن‌ها انجام شد و بعد از مشورت با جناب آقای دکتر آرش انوشیروانی، پزشک فوق تخصص خون و سرطان (هماتولوژی انکولوژی) و تشخیص ایشان در مورد Grade تومور بیماران هر خوشه، به این نتیجه رسیدیم که تومور بیماران سرطانی خوشه اول، Grade 3، خوشه دوم، Grade 1 و خوشه سوم، Grade 2 می‌باشند. این تشخیص با استفاده از پلومورفیسم هسته‌ای انجام شده است که چگونگی تفاوت هسته هر سلول سرطانی از سلول‌های طبیعی را توصیف می‌کند. Grade سرطان را تنها از طریق برداشتن بخشی از سلول‌های سرطانی و بررسی در آزمایشگاه بر این اساس تعیین می‌شود که رفتارهای سلول‌های سرطانی چقدر عادی یا غیر عادی است. از آنجایی که تومور بیماران خوشه دوم، عمدتاً دارای شعاع کمتر، میانگین نقاط مقعر کمتر، میزان تقارن بیشتر و میانگین محیطی اشغال شده‌ی کمتر هستند، بنابراین از نوع سرطان خوش خیم و کم خطر هستند (Grade 1). در مقابل، بیماران خوشه اول که دارای تومورهایی با شعاع بیشتر، میانگین نقاط مقعر بیشتر، میزان تقارن کمتر و میانگین محیطی اشغال شده‌ی بیشتر هستند، از نوع سرطان بدخیم و پیشرفته‌ی می‌باشند (Grade 3). در خوشه‌ی سوم نیز که ویژگی تومورهای آن‌ها ما بین دو خوشه‌ی قبلی است، سلول‌ها با سرعت متوسط رشد می‌کنند و رفتاری مابین سلول‌ها در Grade 1 و Grade 3 دارند (Grade 2).

2.4. پاسخ به سؤالات تحقیق

این مطالعه نشان داد که 59% از بیماران سرطان پستان که اطلاعات آن‌ها در مرکز بالینی آنالیز تومورهای سرطانی ثبت و مورد بررسی قرار گرفته است، سرطانی از Grade 2 دارند. 25% آن‌ها Grade 1 و 16% آن‌ها دارای سرطان پستان با Grade 3 هستند.

برای تعمیم دادن نتایج حاصل از این پژوهش به کل جامعه‌ی آماری که ایالت ویسکانسین آمریکا می‌باشد، بهتر است بیماران سرطانی در مراکز درمانی بیشتری مورد بررسی قرار بگیرند. همچنین برای تشخیص نهایی Grade سرطان هر یک از این بیماران، تعیین بهترین روش درمانی و زمان بندی دوره‌ی درمان آن‌ها باید با متخصصین بیشتری مشورت کرد.

منابع

1. مرادی، محمد، جلیلیان، عبدالله، محاسبات آماری با R، انتشارات علمی پارسین (1396)
2. ت. لاروس، دانیل، دانشیابی داده‌ها، ترجمه علی زینل همدانی، انتشارات دانشگاه صنعتی اصفهان (1397)
3. آ. جانسون، ریچارد، دبلیو. ویچرن، دین، تحلیل آماری چند متغیری کاربردی، ترجمه حسینعلی نیرومند، انتشارات دانشگاه فردوسی مشهد (1399)
4. James, Gareth, Witten, Daniel, Hastie, Trevor, Tibshirani, Robert, An Introduction to Statistical Learning with Applications In R, Springer Texts in Statistics (February 11, 2013)
5. <https://www.kaggle.com/datasets/yasserh/breast-cancer-dataset>
6. https://uc-r.github.io/kmeans_clustering
7. <https://behayand.com>
8. <https://abidipharma.com/health-items/breast-cancer/>
9. <https://www.labset.ir/news/499>
10. <https://raahbord.com/clustering-in-data-mining/>

R Console

```

> install.packages("readxl")
Warning: package 'readxl' is in use and will not be installed
> library(readxl)
> data=read_xls(file.choose())

filepath: D:\LMS\LMS 8\Bachelor project\sample of breast cancer patients.xlsx

>
> breast_cancer_data=cbind(radius_mean,texture_mean,perimeter_mean,area_mean,
+                           smoothness_mean,compactness_mean,concavity_mean,
+                           concave_points_mean,symmetry_mean,fractal_dimension_mean,
+                           radius_se,texture_se,perimeter_se,area_se,smoothness_se,
+                           compactness_se,concavity_se,concave_points_se,symmetry_se,
+                           fractal_dimension_se,radius_worst,texture_worst,perimeter_worst,
+                           area_worst,smoothness_worst,compactness_worst,concavity_worst,
+                           concave_points_worst,symmetry_worst,fractal_dimension_worst)
>
> #####
>
> library(corrplot)
>
> corrplot(cor(breast_cancer_data),method = "number", number.cex = .6, tl.cex = 0.7)
>
> #####

> km <- kmeans( breast_cancer_data , centers = 3)
> km
K-means clustering with 3 clusters of sizes 84, 145, 340

Cluster means:
  radius_mean texture_mean perimeter_mean area_mean smoothness_mean compactness_mean
1   20.46167    21.91845    135.68690 1318.2214      0.10208869      0.15729583
2   15.78207    20.30097    103.45993  777.9524      0.09837152      0.12233834
3   11.85661    18.20888     76.26762  438.5241      0.09408729      0.08358268
  concavity_mean concave_points_mean symmetry_mean fractal_dimension_mean radius_se
1   0.19631333      0.11073524      0.1929643      0.06053726  0.8369274
2   0.11711407      0.06555352      0.1851110      0.06154517  0.4393421
3   0.05016162      0.02655286      0.1765618      0.06389018  0.2839306
  texture_se perimeter_se area_se smoothness_se compactness_se concavity_se
1   1.187938     5.891976 113.74619  0.006585286  0.03360964  0.04531595
2   1.140265     3.144076  43.92179  0.006475055  0.02809362  0.03535130
3   1.256660     1.999914  20.67194  0.007394912  0.02235375  0.02710308
  concave_points_se symmetry_se fractal_dimension_se radius_worst texture_worst
1   0.016093286  0.02069500      0.003942857    25.40429    29.19810
2   0.013623807  0.01928204      0.003743426    18.38490    27.31503
3   0.009955041  0.02104204      0.003780304    13.11000    24.10888
  perimeter_worst area_worst smoothness_worst compactness_worst concavity_worst
1   170.31429  1998.1071      0.1411405      0.3819000      0.4863452
2   122.13103  1045.7379      0.1365846      0.3098713      0.3553823
3    85.34185   534.0553      0.1284034      0.1990173      0.1837995
  concave_points_worst symmetry_worst fractal_dimension_worst
1   0.20587143      0.3154738      0.08712595
2   0.14925545      0.3043338      0.08565145
3   0.07728147      0.2777200      0.08243274

```



```

Clustering vector:
[1] 1 1 1 3 1 3 1 2 3 3 2 2 2 2 3 2 2 2 1 3 3 3 2 1 1 2 2 2 2 2 1 3 2 1 2 2 2 3 3 3 3 3 1 2
[45] 3 1 3 3 3 3 3 3 3 2 2 3 1 2 3 3 3 3 2 3 2 2 3 3 3 3 1 3 1 2 3 2 3 1 1 3 3 3 1 2 3 1 2 1
[89] 3 2 2 2 2 3 2 1 3 3 3 2 2 3 3 3 3 3 3 3 1 3 3 3 3 3 3 3 2 2 2 3 1 1 3 3 3 2 1 2 1 3 2
[133] 2 2 1 3 3 3 3 2 3 3 2 3 3 3 3 3 2 3 3 3 3 3 3 3 2 2 3 3 3 1 1 3 1 2 3 2 1 2 3 2 2 3 3 3
[177] 3 2 3 3 1 1 2 3 2 3 2 3 3 3 3 3 3 3 2 3 2 2 1 2 3 2 1 2 3 2 3 2 3 2 1 3 1 2 2 3 3 3 1 1
[221] 3 3 3 2 3 2 3 2 3 3 2 3 3 1 3 3 1 1 3 2 3 3 3 3 2 3 3 3 3 3 1 3 1 2 1 2 1 2 2 2 1 2 2 2
[265] 2 1 3 3 3 3 3 3 1 3 2 3 3 2 3 3 1 3 1 2 3 3 3 3 3 3 2 2 3 3 3 3 3 3 2 3 1 3 1 3 3 3 3 3
[309] 3 3 3 2 3 3 3 3 3 2 3 3 3 1 3 1 3 3 3 3 2 2 2 3 3 3 3 2 3 1 3 1 2 3 3 1 3 3 3 2 3 3 3 2
[353] 1 2 3 3 3 3 3 3 3 3 2 3 1 1 3 1 1 2 2 1 1 3 2 3 3 3 3 3 3 3 3 2 3 3 3 2 3 3 2 3 3 2 1 3 3
[397] 3 3 3 3 2 3 3 3 3 3 2 3 2 3 3 3 3 2 2 3 3 1 3 3 3 2 3 3 3 3 3 3 3 3 2 3 1 1 2 2 3 3 3 3
[441] 3 2 3 3 2 3 2 2 2 1 3 2 3 3 3 3 3 3 3 1 1 3 3 3 3 3 2 3 3 3 2 3 3 3 2 3 3 2 3 3 2 3 2 3 3
[485] 2 3 2 1 3 2 3 2 2 3 3 2 3 3 1 1 2 3 3 1 3 3 3 3 2 2 3 2 2 2 2 2 1 3 3 3 1 3 3 3 3 3 3 3
[529] 3 3 3 3 3 1 3 1 3 3 3 3 3 2 2 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 2 1 1 1 2 1 3

Within cluster sum of squares by cluster:
[1] 30117250 10030190 10369391
(between_SS / total_SS = 80.3 %)

Available components:

[1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss" "betweenss"
[7] "size"         "iter"         "ifault"
>
> km$size
[1] 84 145 340
>
> pie(km$size,col=c(2,4,5),
+     labels=c("cluster 1","cluster 2","cluster 3"))

> km$withinss
[1] 30117250 10030190 10369391
> km$betweenss
[1] 206160412
> km$centers
  radius_mean texture_mean perimeter_mean area_mean smoothness_mean compactness_mean
1   20.46167    21.91845    135.68690 1318.2214    0.10208869    0.15729583
2   15.78207    20.30097    103.45993  777.9524    0.09837152    0.12233834
3   11.85661    18.20888     76.26762  438.5241    0.09408729    0.08358268
concavity_mean concave_points_mean symmetry_mean fractal_dimension_mean radius_se
1   0.19631333    0.11073524    0.1929643    0.06053726 0.8369274
2   0.11711407    0.06555352    0.1851110    0.06154517 0.4393421
3   0.05016162    0.02655286    0.1765618    0.06389018 0.2839306
texture_se perimeter_se area_se smoothness_se compactness_se concavity_se
1   1.187938    5.891976 113.74619    0.006585286    0.03360964    0.04531595
2   1.140265    3.144076  43.92179    0.006475055    0.02809362    0.03535130
3   1.256660    1.999914  20.67194    0.007394912    0.02235375    0.02710308
concave_points_se symmetry_se fractal_dimension_se radius_worst texture_worst
1   0.016093286  0.02069500    0.003942857    25.40429    29.19810
2   0.013623807  0.01928204    0.003743426    18.38490    27.31503
3   0.009955041  0.02104204    0.003780304    13.11000    24.10888
perimeter_worst area_worst smoothness_worst compactness_worst concavity_worst
1   170.31429 1998.1071    0.1411405    0.3819000    0.4863452
2   122.13103 1045.7379    0.1365846    0.3098713    0.3553823
3    85.34185  534.0553    0.1284034    0.1990173    0.1837995
concave_points_worst symmetry_worst fractal_dimension_worst
1   0.20587143    0.3154738    0.08712595
2   0.14925545    0.3043338    0.08565145
3   0.07728147    0.2777200    0.08243274

```



```

> km$cluster
[1] 1 1 1 3 1 3 1 2 3 3 2 2 2 2 3 2 2 2 1 3 3 3 2 1 1 2 2 2 2 1 3 2 1 2 2 2 3 3 3 3 3 1 2
[45] 3 1 3 3 3 3 3 3 3 2 2 3 1 2 3 3 3 3 2 3 2 2 3 3 3 3 1 3 1 2 3 2 3 1 1 3 3 3 1 2 3 1 2 1
[89] 3 2 2 2 2 3 2 1 3 3 3 2 2 3 3 3 3 3 3 1 3 3 3 3 3 3 3 2 2 2 3 1 1 3 3 3 2 1 2 1 3 2
[133] 2 2 1 3 3 3 2 3 3 2 3 3 3 3 3 2 3 3 3 3 3 3 3 3 2 2 3 3 3 1 1 3 1 2 3 2 1 2 3 2 2 3 3 3
[177] 3 2 3 3 1 1 2 3 2 3 2 3 3 3 3 3 3 2 3 2 2 1 2 3 2 1 2 3 2 3 2 1 3 1 2 2 3 3 3 1 1
[221] 3 3 3 2 3 2 3 2 3 3 2 3 3 1 3 3 1 1 3 2 3 3 3 3 2 3 3 3 3 3 1 3 1 2 1 2 1 2 2 2 1 2 2 2
[265] 2 1 3 3 3 3 3 3 1 3 2 3 3 2 3 3 1 3 1 2 3 3 3 3 3 3 2 2 3 3 3 3 3 3 2 3 1 3 1 3 3 3 3 3
[309] 3 3 3 2 3 3 3 3 3 3 2 3 3 3 1 3 1 3 3 3 3 2 2 2 3 3 3 3 2 3 1 3 1 2 3 3 1 3 3 3 2 3 3 2
[353] 1 2 3 3 3 3 3 3 3 3 3 3 2 3 1 1 3 1 1 2 2 1 1 3 2 3 3 3 3 3 3 3 3 3 2 3 3 3 2 3 3 2 1 3 3
[397] 3 3 3 3 2 3 3 3 3 3 2 3 2 3 3 3 3 2 2 3 3 1 3 3 3 2 3 3 3 3 3 3 3 3 2 3 1 1 2 2 3 3 3 3
[441] 3 2 3 3 2 3 2 2 2 1 3 2 3 3 3 3 3 3 3 3 1 1 3 3 3 3 3 3 2 3 3 3 2 3 3 2 3 3 2 3 2 3 3
[485] 2 3 2 1 3 2 3 2 2 3 3 2 3 3 1 1 2 3 3 1 3 3 3 3 2 2 3 2 2 2 2 3 2 1 3 3 3 1 3 3 3 3 3 3
[529] 3 3 3 3 3 1 3 1 3 3 3 3 3 2 2 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 2 1 1 1 2 1 3
>
> F=(km$betweenss/sum(km$withinss))
> F
[1] 4.081024
>
> #####
>
> install.packages("factoextra")
Warning: package 'factoextra' is in use and will not be installed
>
> library(factoextra) # clustering algorithms & visualization
>
> fviz_cluster(km,data=breast_canser_data)

```